# Orquestación Multi-Agente Distribuida

Pre-entrega Módulo 2 · Coderhouse AI Automation · Mariano Musacchio · Octubre 2026

## Resumen

El agente de triaje de solicitudes de compra del Módulo 1 (un Tools Agent monolítico) se reestructuró con el patrón **Manager-Worker**. Un Manager clasifica la intención del mensaje dentro de una taxonomía cerrada y delega en dos Workers independientes, cada uno en su propio lienzo y con una única tarea atómica:

- **W1 · Extracción y Validación:** convierte el texto libre en una solicitud estructurada y diagnostica qué datos faltan. Interpreta, pero no toca ningún sistema.
- **W2 · Registro:** escribe una solicitud ya validada en la planilla oficial. Ejecuta, pero no interpreta nada (no usa LLM).
- Lo que no es una solicitud de compra (consultas o mensajes fuera de ámbito) se deriva a un comprador humano.

| Workflow | Trigger | Responsabilidad | Nodo de salida |
|---|---|---|---|
| M2 - Manager Compras | Chat Trigger | Clasificar, enrutar, invocar Workers, registrar trazabilidad, responder al usuario | Respuesta_Registro / Respuesta_Incompleta / Respuesta_Escalamiento |
| W1 - Extraccion y Validacion | Execute Workflow Trigger | Texto libre a solicitud estructurada + faltantes | Contrato_Salida / Contrato_Error |
| W2 - Registro Solicitud | Execute Workflow Trigger | Solicitud validada a fila en Google Sheets | Contrato_Salida / Contrato_Error |

# 1. Workflow Manager

El Manager recibe el mensaje por Chat Trigger. **Clasificar_Intencion** (Text Classifier con Claude Sonnet 4.6, temperatura 0) decide la ruta. Las solicitudes de compra pasan por W1 y, si están completas, por W2; las consultas y los mensajes fuera de ámbito se escalan a un humano. Cada invocación queda registrada en la pestaña Log.

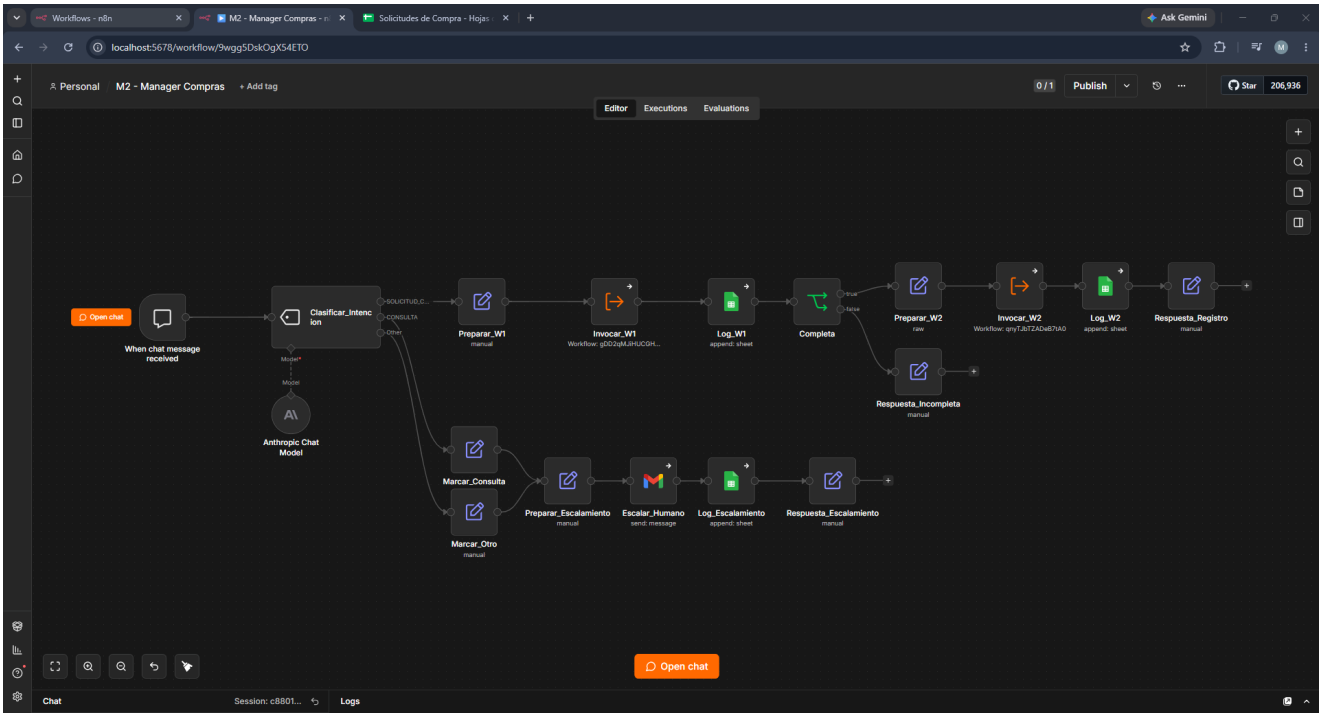



*Figura 1. Lienzo completo del Manager. Arriba, la ruta SOLICITUD_COMPRA con los dos nodos Execute Workflow (Invocar_W1 e Invocar_W2); abajo, la vía de escape (CONSULTA y Other) hacia el escalamiento humano.*

## Recorrido de cada ruta

| Ruta | Nodos |
|---|---|
| SOLICITUD_COMPRA completa | Preparar_W1 → Invocar_W1 → Log_W1 → Completa (true) → Preparar_W2 → Invocar_W2 → Log_W2 → Respuesta_Registro |
| SOLICITUD_COMPRA incompleta | Preparar_W1 → Invocar_W1 → Log_W1 → Completa (false) → Respuesta_Incompleta |
| CONSULTA / Other | Marcar_Consulta o Marcar_Otro → Preparar_Escalamiento → Escalar_Humano (Gmail) → Log_Escalamiento → Respuesta_Escalamiento |

## 2. Workers (sub-workflows)

Cada Worker vive en su propio lienzo, arranca con **Execute Workflow Trigger** (When Executed by Another Workflow) con sus campos de entrada declarados, y termina siempre en uno de dos nodos de contrato: **Contrato_Salida** si terminó bien o **Contrato_Error** si falló. Así el Manager recibe siempre un JSON con la misma forma.

### W1 · Extracción y Validación

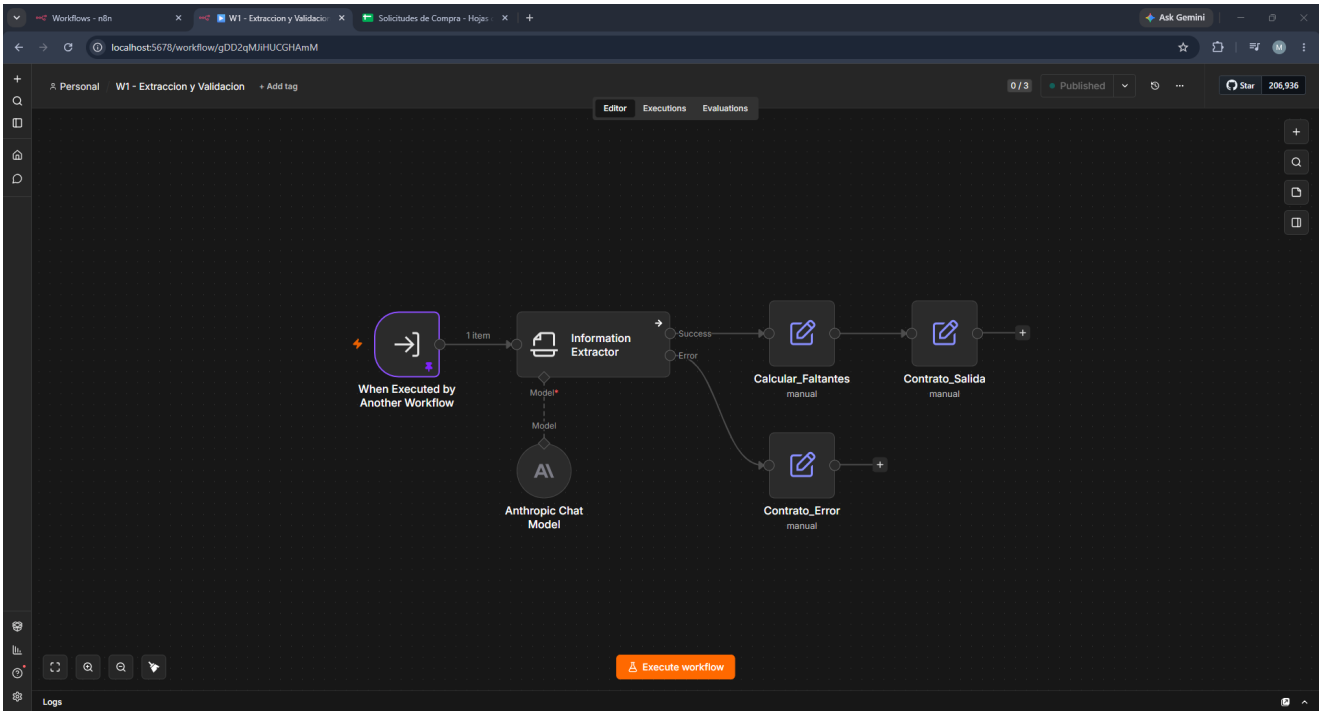



*Figura 2. W1: trigger con entrada declarada, Information Extractor (Anthropic) con salida de error activada, Calcular_Faltantes y los dos contratos.*

El Information Extractor solo extrae campos. La regla de completitud la aplica **Calcular_Faltantes** con una expresión determinista: descripción, cantidad mayor a 0, unidad y área son obligatorias, y la justificación es obligatoria cuando la prioridad no es Normal. Así la regla de negocio se cumple siempre y no depende de que el modelo la respete.

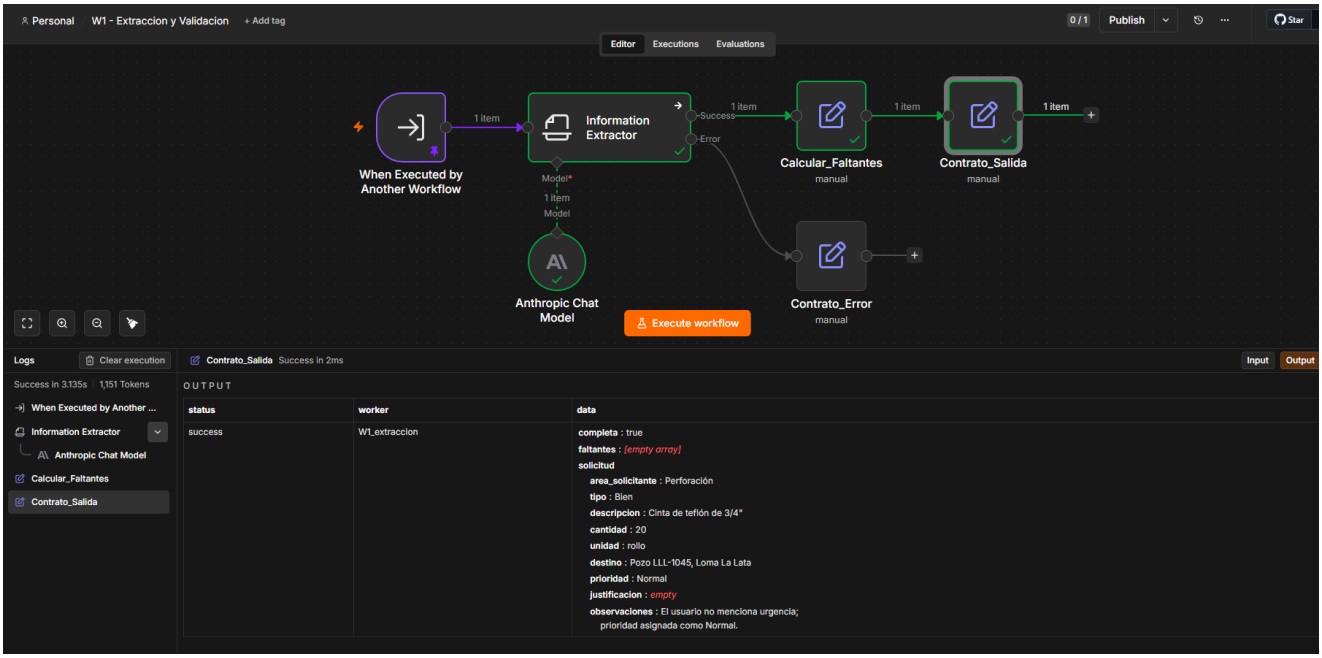



*Figura 3. Salida de W1 para un pedido completo: status success, completa true, faltantes vacío y la solicitud normalizada (1.151 tokens).*

## W2 · Registro

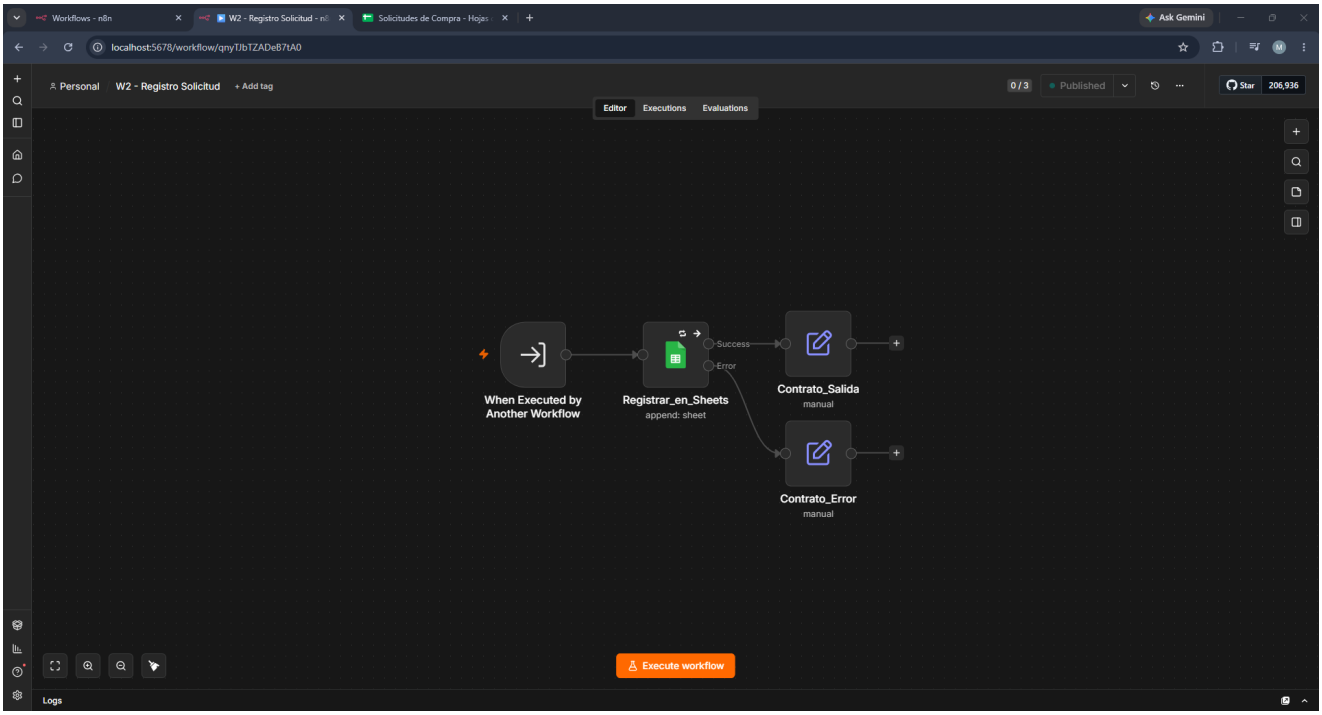



*Figura 4. W2: trigger, Registrar_en_Sheets (Append Row con reintento: 2 intentos, 1 s de espera; salida de error activada) y los dos contratos. No consume tokens.*

## 3. Handoff de datos: Execute Workflow

Antes de cada invocación, un nodo **Set** con *Include Other Input Fields* desactivado arma la entrada mínima del Worker. Así se evita el pasillo de la muerte: W1 recibe dos campos y no la metadata del trigger ni la salida del clasificador.

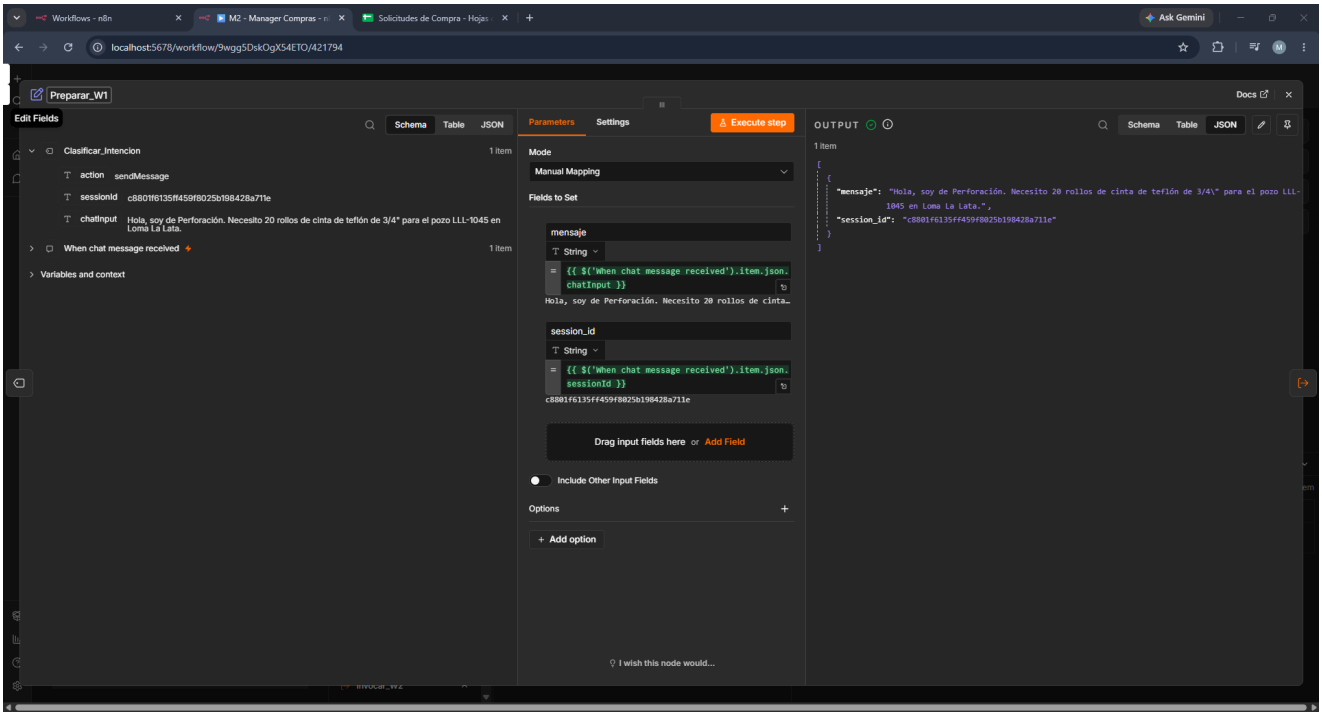



*Figura 5. Preparar_W1: solo pasan mensaje y session_id (salida JSON a la derecha). Include Other Input Fields desactivado.*

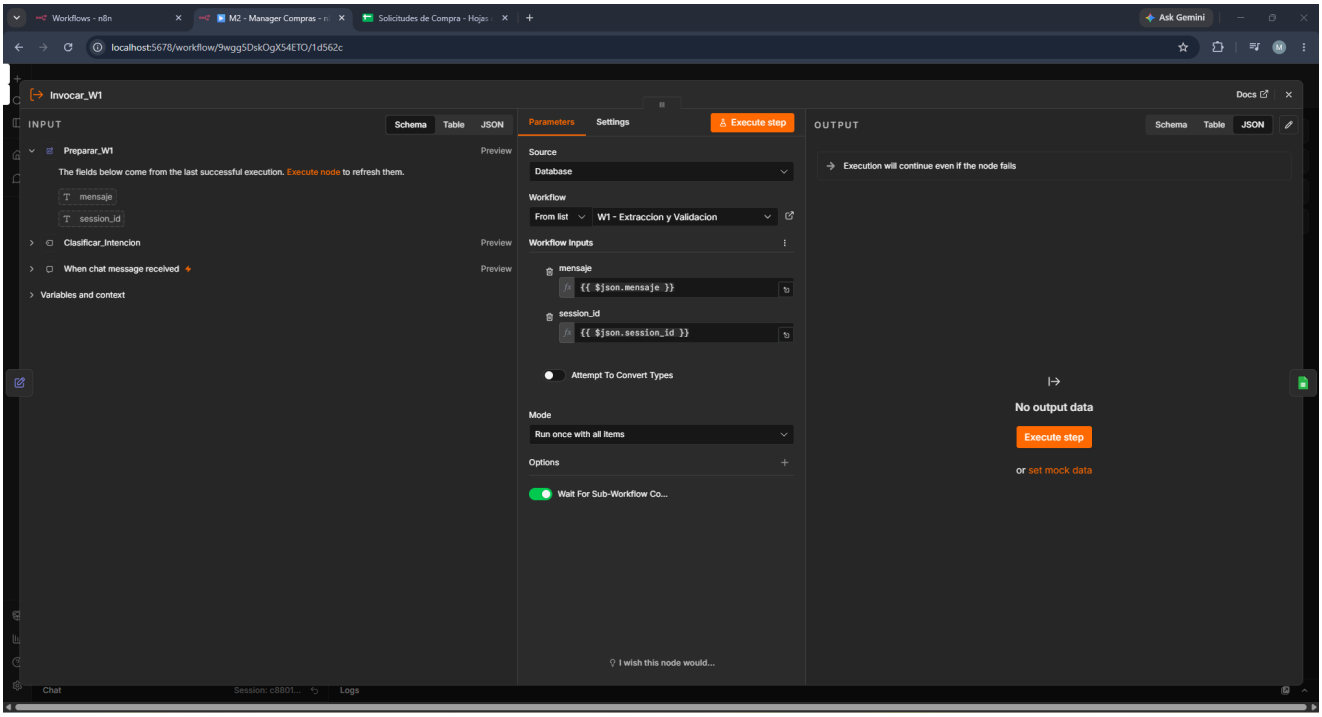



*Figura 6. Invocar_W1: workflow W1 elegido desde la base, mapeo de los dos campos del contrato de entrada y Wait For Sub-Workflow Completion activado. Con On Error en Continue, un fallo de W1 no bloquea al Manager.*

Invocar_W2 tiene la misma configuración: workflow W2, diez campos de entrada mapeados desde Preparar_W2 y espera activada.

# 4. Ejecución de punta a punta

Prueba con el mensaje *“Hola, soy de Perforación. Necesito 20 rollos de cinta de teflón de 3/4" para el pozo LLL-1045 en Loma La Lata.”* El Manager delega en W1, recibe la solicitud completa, delega en W2 y devuelve al chat la confirmación integrada.

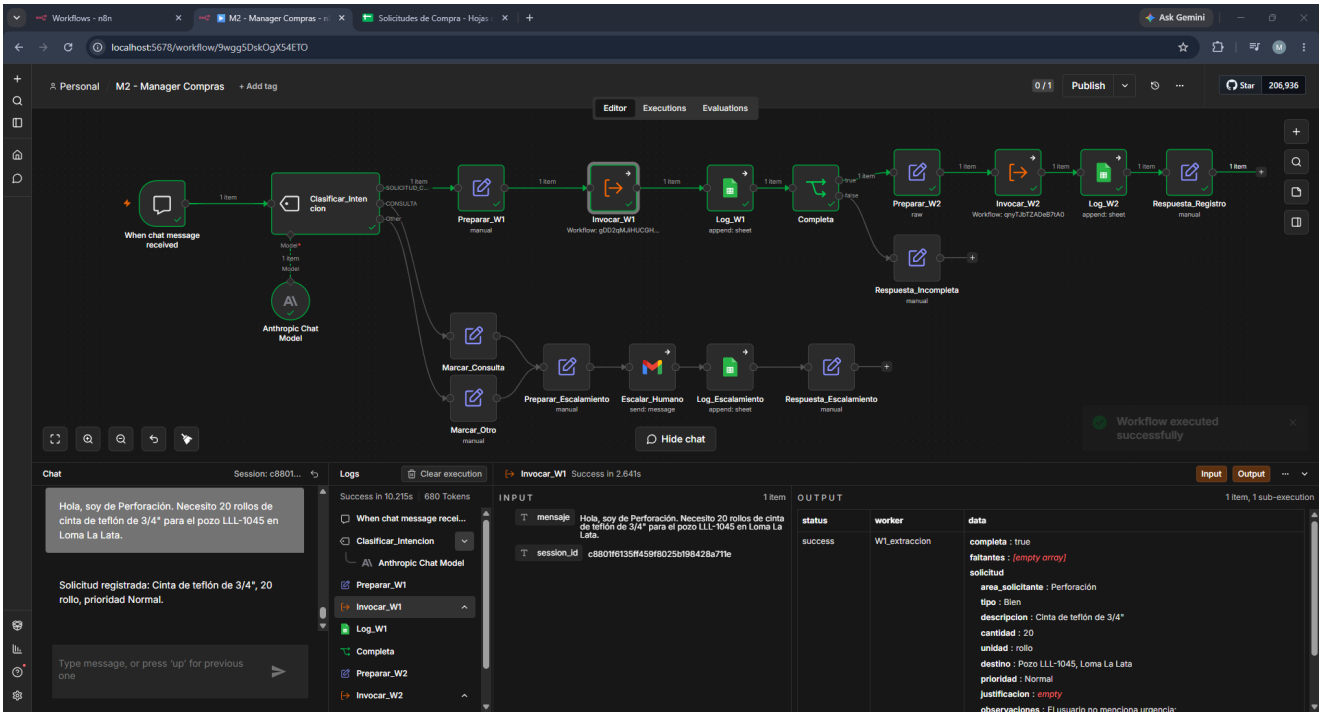



*Figura 7. Corrida exitosa: la ruta superior queda en verde, Invocar_W1 muestra “1 item, 1 sub-execution” con el contrato de W1, y el chat responde “Solicitud registrada: Cinta de teflón de 3/4", 20 rollo, prioridad Normal.”*

| Prueba | Ruta | Respuesta al usuario |
|---|---|---|
| Teflón, pedido completo | W1 → W2 | Solicitud registrada: Cinta de teflón de 3/4", 20 rollo, prioridad Normal. |
| Guantes, urgente sin justificar | W1 (completa = false) | No se registró la solicitud. Faltan: justificacion. |
| ¿Cuándo llegan las válvulas…? | CONSULTA → humano | Tu consulta fue derivada al área de Abastecimiento… |
| ¿Me pasás el menú del comedor? | Other → humano | Este asistente solo gestiona solicitudes de compra… |

## 5. Esquema de datos entre Manager y Workers

Los dos Workers comparten el mismo contrato de salida: **status** indica cómo terminó, **worker** quién responde y **data** el resultado. Ante un fallo, la forma se mantiene y **data** se reemplaza por **error**. El Manager decide leyendo solo **status** y **data.completa**, sin conocer el interior del Worker.

### Manager → W1 (entrada)

```
{
  "mensaje": "Necesito 10 pares de guantes de nitrilo para Mantenimiento, es urgente.",
  "session_id": "c8801f6135ff459f8025b198428a711e"
}
```

### W1 → Manager (salida)

```
{
  "status": "success",
  "worker": "W1_extraccion",
  "data": {
    "completa": false,
    "faltantes": ["justificacion"],
    "solicitud": {
      "area_solicitante": "Mantenimiento", "tipo": "Bien",
      "descripcion": "Guantes de nitrilo", "cantidad": 10, "unidad": "par",
      "destino": "", "prioridad": "Urgente", "justificacion": "",
      "observaciones": "El usuario indicó urgencia pero no proporcionó una justificación..."
    }
  }
}
```

### Manager → W2 (entrada)

Solo session_id y los nueve campos de la solicitud. No viajan status, worker, completa ni faltantes, porque W2 no los necesita.

```
{ "session_id": "c8801f...", "area_solicitante": "Perforación", "tipo": "Bien",
  "descripcion": "Cinta de teflón de 3/4\"", "cantidad": 20, "unidad": "rollo",
  "destino": "Pozo LLL-1045, Loma La Lata", "prioridad": "Normal",
  "justificacion": "", "observaciones": "El usuario no menciona urgencia; ..." }
```

### W2 → Manager (salida) y contrato de error

```
{ "status": "success", "worker": "W2_registro",
  "data": {
    "registrada": true,
    "mensaje_usuario": "Solicitud registrada: Cinta de teflón de 3/4\", 20 rollo,
                        prioridad Normal."
  }
}

{ "status": "error", "worker": "W2_registro",
  "error": "The resource you are requesting could not be found" }
```

Los datos ausentes viajan como cadena vacía (y 0 en cantidad), no como null. Así los tipos se mantienen estables en el parser estructurado y en la planilla.

## 6. Criterio de enrutamiento

El enrutamiento combina dos niveles: un **clasificador semántico**, porque el lenguaje del usuario es libre, y una **decisión determinista de costo cero tokens** para todo lo que se puede resolver con reglas.

| Nivel | Nodo | Criterio | Costo |
|---|---|---|---|
| 1 · Intención | Clasificar_Intencion (Text Classifier, temp. 0) | Taxonomía cerrada: SOLICITUD_COMPRA, CONSULTA; el resto o lo dudoso sale por Other | ~650 tokens |
| 2 · Completitud | Completa (If) | status = success Y data.completa = true → W2; si no, respuesta de faltantes o de error técnico | 0 tokens |
| 3 · Resultado | Respuesta_* (Set) | Mensaje al usuario según status del Worker; nunca se muestra un JSON ni un error crudo | 0 tokens |

| Categoría | Descripción para el clasificador | Destino |
|---|---|---|
| SOLICITUD_COMPRA | Pide que se compre, provea o contrate un bien o servicio. Incluye pedidos incompletos, urgentes o con datos faltantes. | W1 |
| CONSULTA | Pregunta por el estado de un pedido existente, plazos, precios, cotizaciones, proveedores o stock, sin pedir una compra nueva. | Comprador humano |
| Other (fallback) | Sin coincidencia clara (opción When No Clear Match: Output on Extra, 'Other' Branch). | Comprador humano |

La aclaración “incluye pedidos incompletos” evita que el clasificador mande a Other pedidos válidos a los que les falta un dato: decidir la completitud es trabajo de W1, no del clasificador. CONSULTA se escala porque, sin identificador de pedido ni memoria de sesión (Módulo 3), un Worker automático no podría responder bien.

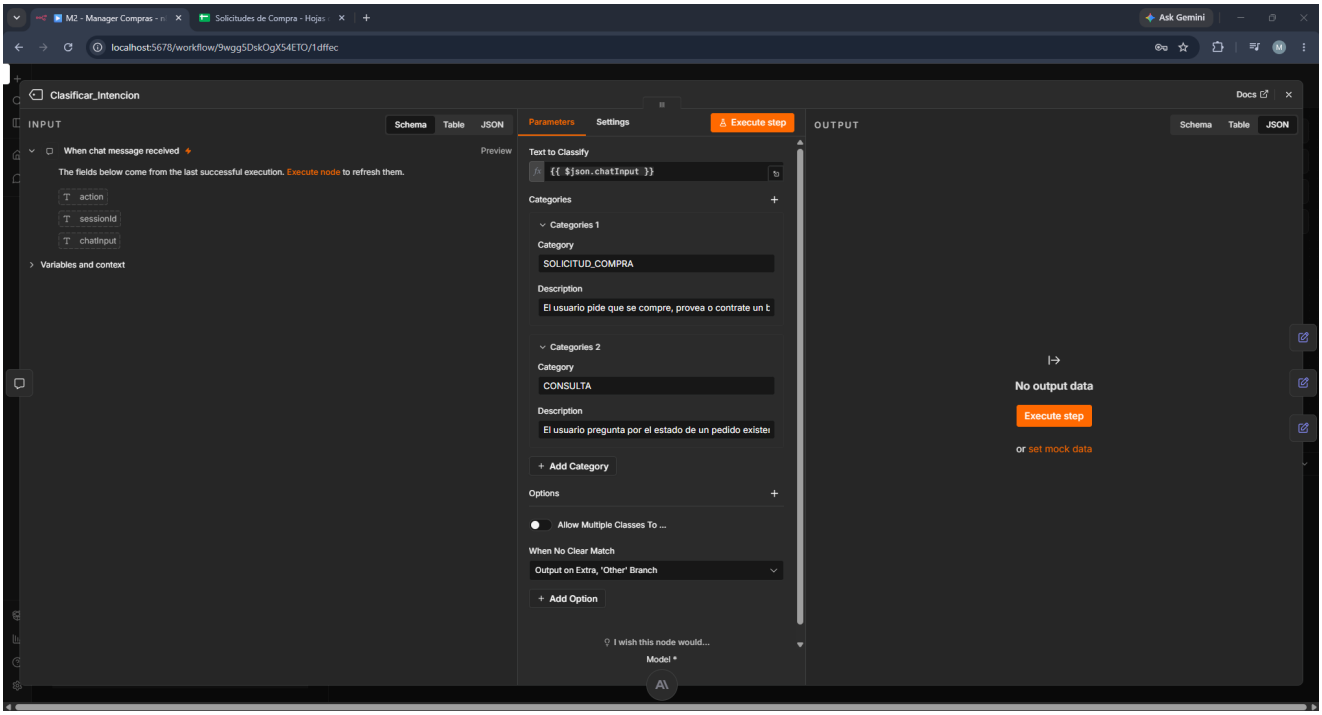



*Figura 8. Configuración del clasificador: dos categorías, Allow Multiple Classes desactivado y fallback a la rama Other.*

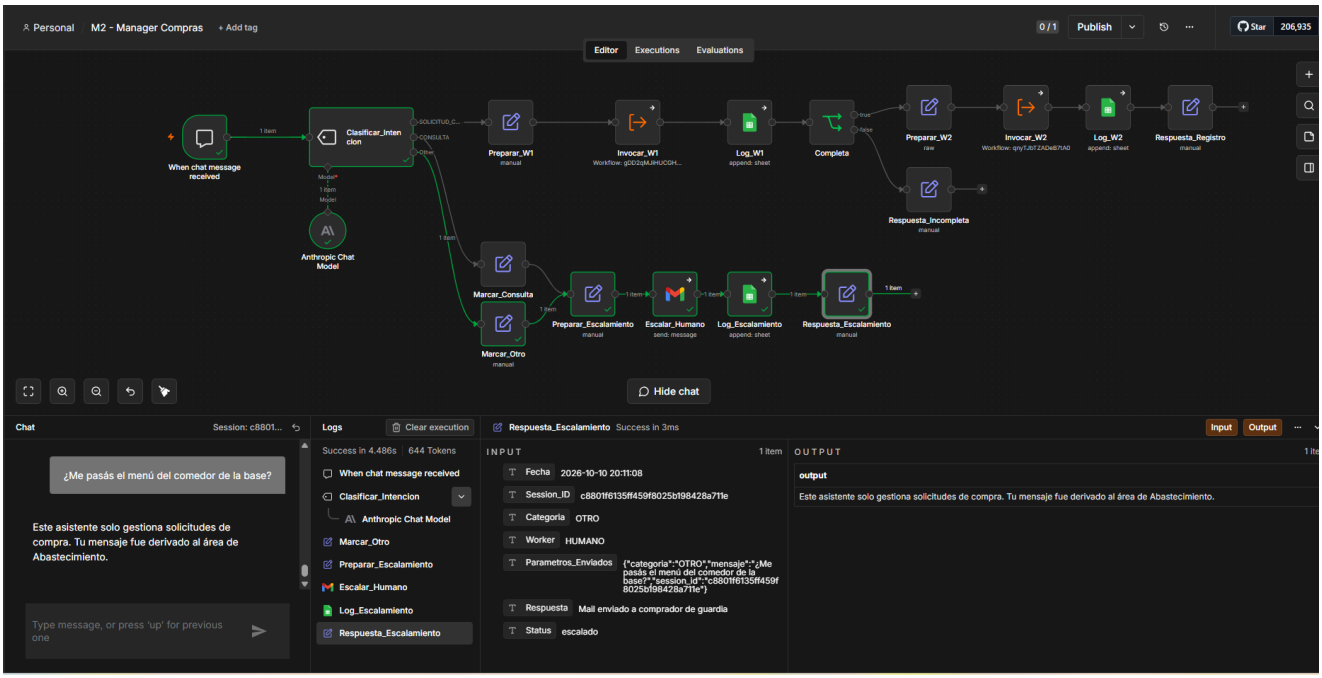



*Figura 9. Vía de escape: un mensaje fuera de ámbito sale por Other, se notifica al comprador por Gmail, se registra con Worker HUMANO y status escalado, y el usuario recibe una respuesta clara.*

# 7. Tiempo de espera y manejo de fallos

| Riesgo | Mitigación |
|---|---|
| Worker lento o colgado (latencia de API) | Timeout Workflow de 30 s en W1 y W2. Una extracción tarda 3–5 s, así que el margen es amplio sin dejar al Manager esperando indefinidamente. |
| Fallo transitorio de Google Sheets | Retry On Fail en Registrar_en_Sheets: 2 intentos con 1 s de espera. |
| Fallo del LLM o de la API en el Worker | On Error: Continue (using error output) hacia Contrato_Error, que devuelve status error con el mismo esquema. |
| Worker caído o timeout vencido | On Error: Continue en Invocar_W1 e Invocar_W2. El If y las respuestas tratan cualquier status distinto de success como error técnico. |
| Falla del log | On Error: Continue en los nodos de log: la auditoría no puede frenar la operación. |

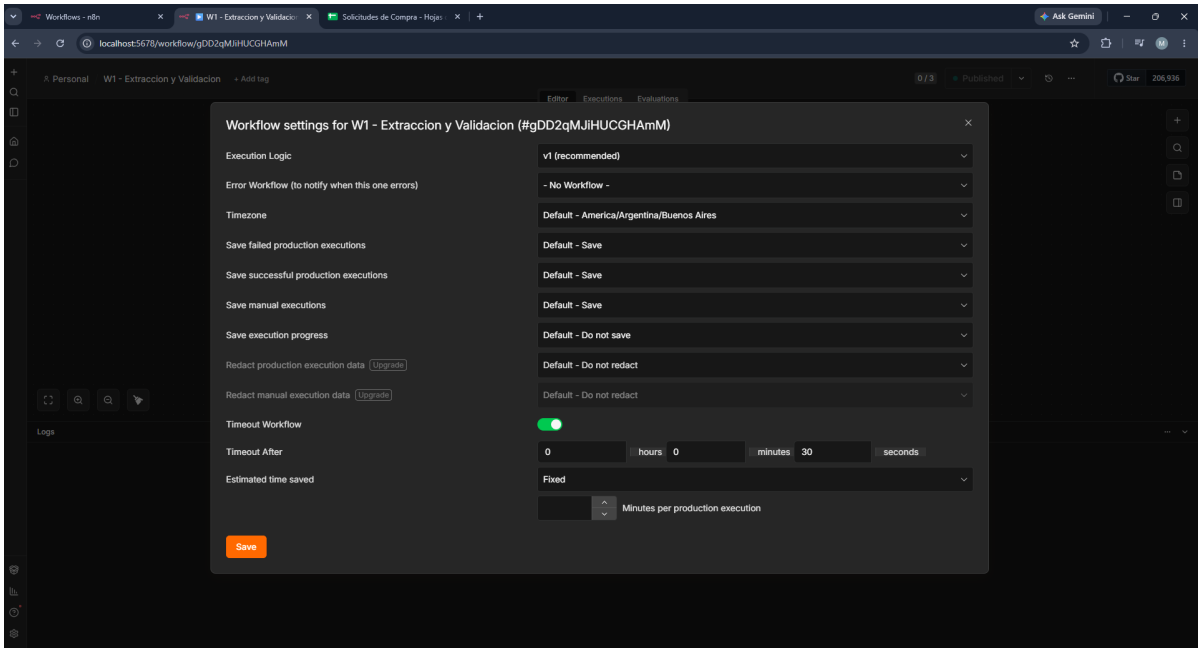



*Figura 10. Settings de W1: Timeout Workflow activado en 30 segundos (W2 tiene la misma configuración).*

## Prueba de fallo forzado

Se apuntó W2 a un ID de planilla inexistente. W2 falló, reintentó y devolvió su contrato de error; el Manager no se bloqueó: registró el error en el Log y respondió al usuario con un mensaje de error técnico. Después se restauró W2 y se verificó que volviera a registrar.

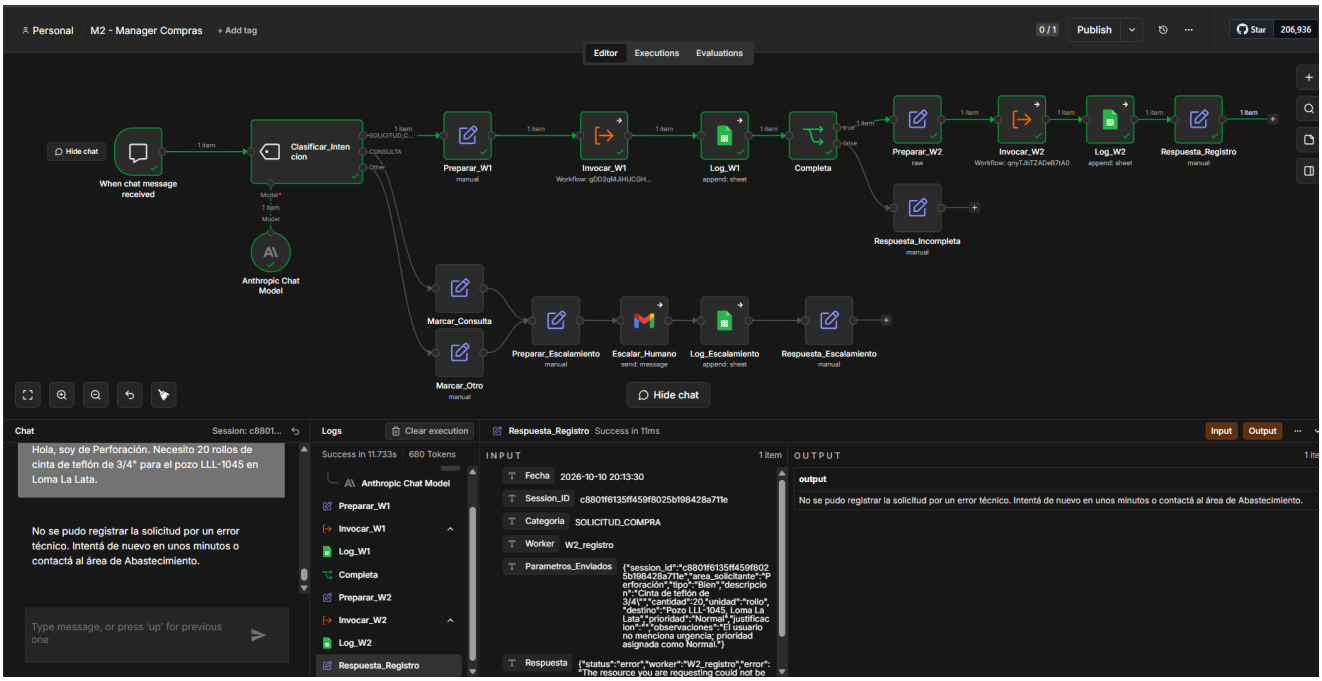
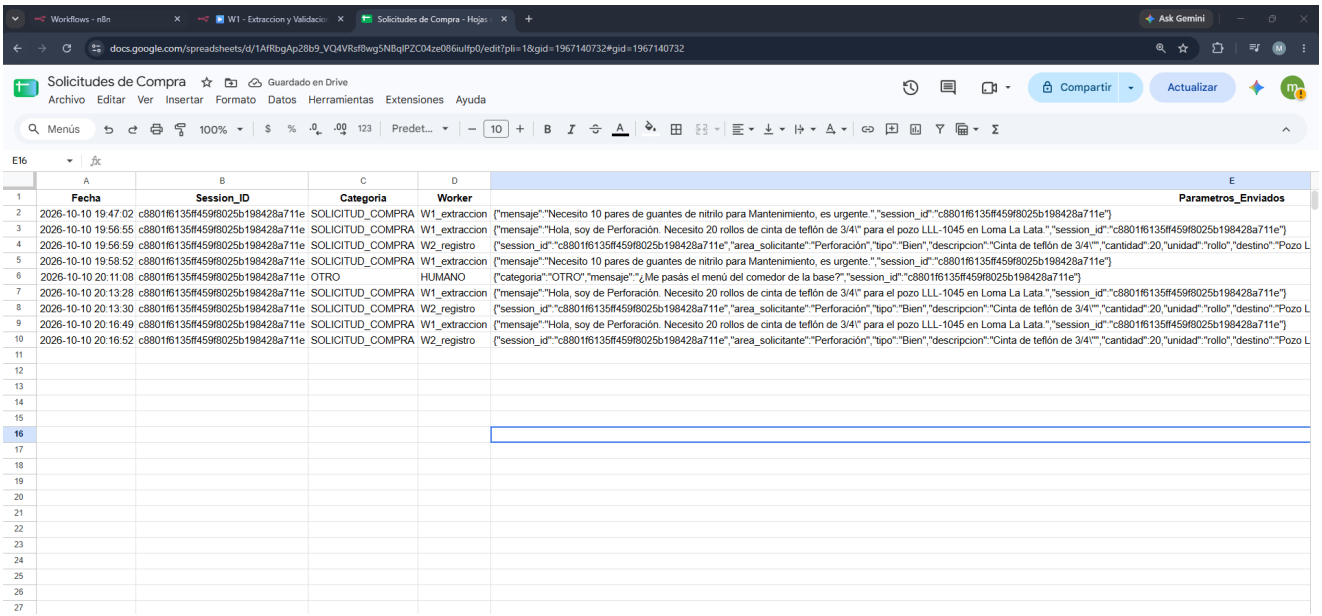



*Figura 11. Fallo forzado de W2: el Manager termina en verde, Log_W2 registra la respuesta {"status":"error","worker":"W2_registro",...} y el chat informa el error técnico al usuario.*

# 8. Log de trazabilidad

Cada invocación escribe una fila en la pestaña **Log** de la planilla *Solicitudes de Compra*, con qué Worker se invocó, qué parámetros se le enviaron y qué devolvió. Una solicitud registrada genera dos filas (W1 y W2) con el mismo Session_ID; un escalamiento genera una fila con Worker HUMANO.

| Columna | Contenido |
|---|---|
| Fecha | Fecha y hora de la invocación |
| Session_ID | Sesión del chat; permite reconstruir la conversación (base para la memoria del Módulo 3) |
| Categoria | SOLICITUD_COMPRA, CONSULTA u OTRO |
| Worker | W1_extraccion, W2_registro o HUMANO |
| Parametros_Enviados | JSON exacto que recibió el Worker |
| Respuesta | JSON exacto que devolvió el Worker |
| Status | success, error o escalado |




| Fecha | Session_ID | Categoria | Worker | Parametros_Enviados |
|---|---|---|---|---|
| 2026-10-10 19:47:02 | c8801f6135ff459f8025b198428a711e | SOLICITUD_COMPRA | W1_extraccion | {"mensaje":"Necesito 10 pares de guantes de nitrilo para Mantenimiento, es urgente.","session_id":"c8801f6135ff459f8025b198428a711e"} |
| 2026-10-10 19:56:55 | c8801f6135ff459f8025b198428a711e | SOLICITUD_COMPRA | W1_extraccion | {"mensaje":"Hola, soy de Perforación. Necesito 20 rollos de cinta de teflón de 3/4\" para el pozo LLL-1045 en Loma La Lata.","session_id":"c8801f6135ff459f8025b198428a711e"} |
| 2026-10-10 19:56:59 | c8801f6135ff459f8025b198428a711e | SOLICITUD_COMPRA | W2_registro | {"session_id":"c8801f6135ff459f8025b198428a711e","area_solicitante":"Perforación","tipo":"Bien","descripcion":"Cinta de teflón de 3/4\"","cantidad":20,"unidad":"rollo","destino":"Pozo L |
| 2026-10-10 19:58:52 | c8801f6135ff459f8025b198428a711e | SOLICITUD_COMPRA | W1_extraccion | {"mensaje":"Necesito 10 pares de guantes de nitrilo para Mantenimiento, es urgente.","session_id":"c8801f6135ff459f8025b198428a711e"} |
| 2026-10-10 20:11:08 | c8801f6135ff459f8025b198428a711e | OTRO | HUMANO | {"categoria":"OTRO","mensaje":"¿Me pasás el menú del comedor de la base?","session_id":"c8801f6135ff459f8025b198428a711e"} |
| 2026-10-10 20:13:28 | c8801f6135ff459f8025b198428a711e | SOLICITUD_COMPRA | W1_extraccion | {"mensaje":"Hola, soy de Perforación. Necesito 20 rollos de cinta de teflón de 3/4\" para el pozo LLL-1045 en Loma La Lata.","session_id":"c8801f6135ff459f8025b198428a711e"} |
| 2026-10-10 20:13:30 | c8801f6135ff459f8025b198428a711e | SOLICITUD_COMPRA | W2_registro | {"session_id":"c8801f6135ff459f8025b198428a711e","area_solicitante":"Perforación","tipo":"Bien","descripcion":"Cinta de teflón de 3/4\"","cantidad":20,"unidad":"rollo","destino":"Pozo L |
| 2026-10-10 20:16:49 | c8801f6135ff459f8025b198428a711e | SOLICITUD_COMPRA | W1_extraccion | {"mensaje":"Hola, soy de Perforación. Necesito 20 rollos de cinta de teflón de 3/4\" para el pozo LLL-1045 en Loma La Lata.","session_id":"c8801f6135ff459f8025b198428a711e"} |
| 2026-10-10 20:16:52 | c8801f6135ff459f8025b198428a711e | SOLICITUD_COMPRA | W2_registro | {"session_id":"c8801f6135ff459f8025b198428a711e","area_solicitante":"Perforación","tipo":"Bien","descripcion":"Cinta de teflón de 3/4\"","cantidad":20,"unidad":"rollo","destino":"Pozo L |

*Figura 12. Pestaña Log después de las pruebas: invocaciones de W1 y W2 con el mismo Session_ID y un escalamiento OTRO a HUMANO.*

# 9. Decisiones de diseño

- **Workers por etapa, no por intención.** W1 interpreta y W2 ejecuta. Cada uno tiene una sola tarea, y en una misma corrida hay dos handoffs encadenados.
- **Lo determinista sale del modelo.** La completitud, la fecha, el Session_ID, el estado y los mensajes al usuario se calculan con expresiones; el LLM solo clasifica y extrae.
- **Destino opcional.** El comprador puede completarlo en la gestión; se priorizó no rechazar pedidos válidos mientras no haya memoria conversacional.
- **Costo.** Una solicitud registrada consume unos 1.800 tokens (clasificador ~650 + W1 ~1.150; W2 no usa LLM), contra unos 5.200 del agente monolítico del Módulo 1, que hacía una segunda vuelta para leer el resultado de su tool.
- **Versionado.** W1 y W2 se publican con versiones nombradas (v1.0, v1.1 prueba de fallo, v1.2 restaurado). El Manager invoca la versión publicada.